



AI 每日快报 — 2026-05-13

面向算法工程师的个人科技情报流

一、AI & 科技快讯

极客公园

- [Auto Research 来了：当 AI 开始接管科研里最苦的活，意味着什么](#)
- [免费 1500 次背后，商汤在下一盘什么棋](#)
- [AI 为什么一定会成为这代人的全新购物入口](#)
- [谷歌在安卓上全面强化 Gemini AI；宇树发布全球首款载人机甲，售价 390 万元；追觅高管回应「崩老头」](#)
- [谷歌开了一场「读作 Android，写作 Gemini」的硬件发布会](#)
- [在中国市场搞「付费订阅」，豆包咋想的？](#)
- [对话维他动力余轶南：融资 5 亿，如何跨过从 Demo 到量产的 5 个月](#)
- [传可灵计划独立融资上市：300 亿美元的快手长出 200 亿美元的 AI 视频子公司](#)
- [OpenAI 前 CTO，拿出一个「最人性」的 AI](#)
- [0.2 元 / 通，淘天用 AI 店小蜜重新定义了电商客服价格](#)
- [OPPO 就母亲节文案发布问责通告；OpenAI 投资 40 亿美元成立新公司加速企业级 AI 落地；Claude 勒索行为源于网络邪恶信息](#)
- [Figure AI 发布新 demo：两个机器人点头致意，我们一起把被子拉开](#)
- [OTA 升级后续航减 200 KM，央视揭秘新能源汽车「锁电」真相；黄仁勋：别怕 AI，今天是应届生最好时机；微信测试「组合支付」功能 | 极客早知道](#)
- [华为 Pura X Max 卖爆了，但「阔折叠」还只赢了一半](#)
- [Altman 或官宣 OpenAI 硬件；李想谈 L9 4 年才换代：汽车非手机，AI 帮助有限；多家车企否认「被约谈」](#)
- [被 AI 重新激活的「无屏手环」，成了大厂争抢的运动健康新赛道](#)
- [Genesis AI 发布新模型：机器人开始挑战西红柿炒鸡蛋](#)
- [苹果和英特尔，分手六年后，又「在一起」了](#)
- [OSMO Pocket 4P，是大疆自己打响的「云台相机下半场」第一枪](#)
- [Anthropic 估值逼近 1 万亿美元；OpenAI 推出 Codex Chrome 扩展：消息称腾讯实习生大涨薪，百度「全员晋升」 | 极客早知道](#)
- [消除「AI 学习门槛」，这个 Agent 想让普通人「无脑上手」](#)
- [550 亿美元！马斯克的「芯片工厂」开始成为现实](#)
- [扫地机祖师爷再创业：造了一只懂你的「人造赛博宠物」](#)
- [美团推「养虾社区」；OpenAI 推出三款实时语音模型；宇树机器人在韩国佛门「受戒」，法名「迦悲」](#)
- [比 OpenClaw 更火的「Agent 员工」赛道，杀出一个新王者 | AI 上新](#)
- [平头哥发布首款智能网卡「磐脉 920」，补齐 AI 算力最后一块短板](#)

- [传月之暗面新融 20 亿美元，估值超 200 亿美元；豆包曝光首个全模态理解模型；开播 24 年后， 星空卫视停播 | 极客早知道](#)
- [实测纳逗 Pro：能做专业影视级内容的智能平台长啥样](#)
- [Anthropic 搞了个全是 AI 的闲鱼群，大模型在里面互割起了韭菜](#)
- [谷歌、英伟达押注，这家估值 40 亿美元的 AI 公司，想把科学家直接干掉](#)

36Kr

- [林俊旸创业，新公司估值约 20 亿美金 | 智能涌现独家](#)
- [6 月上海，这场论坛聊透出海真问题](#)
- [36 氪专访 | 安克创新 eufyMake 负责人：众筹超 4000 万美金后，还在红海寻找缝隙](#)
- [36 氪首发 | 清华系光计算芯片企业完成数千万天使轮融资，瞄准全波光计算架构](#)
- [深耕“具身智能+建筑大模型”底座，重构万亿建筑业，「方石机器人」完成近亿元 A 轮融资 | 36 氪首发](#)
- [8 点 1 氪 | 宇树发布载人变形机甲，定价 390 万起；微信确认不会开发已读、访客功能；国内航线燃油附加费将再上调](#)
- [氪星晚报 | 宇树科技发布载人机甲，投资人回应；京东：第一季度营收 3157 亿元，日本恩格尔系数创 1980 年以来最高水平同比增长 4.9%](#)
- [不用再找了，AI 落地最全的实战打法，都在亦庄这场大会里](#)
- [Walulu：用六个月撕开一条新赛道](#)
- [36 氪首发 | 新加坡博士团队创业获种子轮融资，首款产品做“会飞的家庭管家”](#)
- [阿里巴巴：2026 财年 Q4 营收 2433.8 亿元，同比增长 3%](#)
- [华秦科技：签订约 14.80 亿元航空发动机用特种功能材料销售框架协议](#)
- [国际能源署：全球石油库存正以创纪录速度下降](#)
- [株洲市资源投资集团增资至 40 亿，增幅约 33%](#)
- [沪电股份：泰国基地 AI 服务器与高速网络产品批量导入，2026 年第一季度产能利用率超 90%](#)
- [通光线缆：股票异常波动期间 控股股东通光集团累计减持 252.72 万股公司股票](#)
- [泰格医药：拟 5 亿元至 10 亿元回购股份](#)
- [市场监管总局：推动价格法等多部法律法规修订](#)
- [市场监管总局：开展破除妨碍统一市场和公平竞争卡点堵点专项行动](#)
- [市场监管总局：严查算法违规乱象，规范市场竞争秩序](#)
- [市场监管总局：开展破除妨碍统一市场和公平竞争卡点堵点专项行动](#)
- [香港立法会通过税务宽免条例草案，特区政府表示欢迎](#)
- [恒瑞医药：子公司三款药物获临床试验批准通知书](#)
- [湘财股份：上交所恢复审核公司换股吸收合并大智慧事项](#)
- [燃油附加费涨价引爆囤票潮，端午节订票量涨 84%](#)
- [乘联分会：5 月 1—10 日全国乘用车市场新能源零售 22.6 万辆，环比增长 27%](#)
- [上海启动赴金门、马祖旅游签注申请受理](#)

- [腾讯: Hy3 preview 调用量持续居 OpenRouter 榜首, Agent 密集发布](#)
- [腾讯: 本土市场游戏收入 454 亿元, 同比增长 6%](#)
- [韩国总统李在明会见何立峰](#)

OpenAI Blog

- [How finance teams use Codex](#)
- [How NVIDIA engineers and researchers build with Codex](#)
- [What Parameter Golf taught us about AI-assisted research](#)
- [AutoScout24 scales engineering with AI-powered workflows](#)
- [How ChatGPT adoption broadened in early 2026](#)
- [How enterprises are scaling AI](#)
- [OpenAI Campus Network: Student club interest form](#)
- [OpenAI launches DeployCo to help businesses build around intelligence](#)
- [Running Codex safely at OpenAI](#)
- [Scaling Trusted Access for Cyber with GPT-5.5 and GPT-5.5-Cyber](#)
- [Parloa builds service agents customers want to talk to](#)
- [Advancing voice intelligence with new models in the API](#)
- [Introducing Trusted Contact in ChatGPT](#)
- [Testing ads in ChatGPT](#)
- [Simplex rethinks software development with Codex](#)
- [How ChatGPT learns about the world while protecting privacy](#)
- [Introducing ChatGPT Futures: Class of 2026](#)
- [Singular Bank helps bankers move fast with ChatGPT and Codex](#)
- [How frontier firms are pulling ahead](#)
- [Uber uses OpenAI to help people earn smarter and book faster](#)
- [Unlocking large scale AI training networks with MRC \(Multipath Reliable Connection\)](#)
- [GPT-5.5 Instant: smarter, clearer, and more personalized](#)
- [GPT-5.5 Instant System Card](#)
- [New ways to buy ChatGPT ads](#)
- [Advancing youth safety and wellbeing in EMEA](#)
- [OpenAI and PwC collaborate to reimagine the office of the CFO](#)
- [How OpenAI delivers low-latency voice AI at scale](#)
- [Introducing Advanced Account Security](#)
- [Where the goblins came from](#)
- [Building the compute infrastructure for the Intelligence Age](#)

TechCrunch AI

- [Medicare's new payment model is built for AI, and most of the tech world has no idea](#)
- [Musk mulled handing OpenAI to his children, Altman testifies](#)

- [Anthropic warns investors against secondary platforms offering access to its shares](#)
- [Report: Google and SpaceX in talks to put data centers into orbit](#)
- [Everything Google announced at its Android Show, from Googlebooks to vibe-coded widgets](#)
- [Google adds Gemini-powered dictation to Gboard, which could be bad news for dictation startups](#)
- [The AI legal services industry is heating up — Anthropic is getting in on the action](#)
- [Google brings agentic AI and vibe-coded widgets to Android](#)
- [Google's 'Create My Widget' feature will let you vibe-code your own widgets](#)
- [Threads tests a Meta AI integration that works similarly to Grok](#)
- [Dessn raises \\$6M for its production-focused design tool](#)
- [AI voice startup Vapi hits \\$500M valuation after winning Amazon Ring over 40 rivals](#)
- [Thinking Machines wants to build an AI that actually listens while it talks](#)
- [Riding an AI rally, Robinhood preps second retail venture IPO](#)
- [GM just laid off hundreds of IT workers to hire those with stronger AI skills](#)
- [Digg tries again, this time as an AI news aggregator](#)
- [There aren't enough rockets for space data centers — Cowboy Space raised \\$275M to build them](#)
- [Get ready for the whisper-filled office of the future](#)
- [Anthropic says 'evil' portrayals of AI were responsible for Claude's blackmail attempts](#)
- [We're feeling cynical about xAI's big deal with Anthropic](#)

The Verge

- [Data centers are coming for rural America](#)
- [Amazon's Panos Panay addresses new Fire phone rumors](#)
- [Sony's new Xperia phone gets an overdue redesign](#)
- [Sam Altman was winning on the stand, but it might not be enough](#)
- [iOS 27 might add a lot more customization to the Camera app](#)
- [Meta won't let you block its AI account on Threads](#)
- [Meta will tell parents when their teens add new interests to their Instagram algorithm](#)
- [Sam Altman says Elon Musk's mind games were damaging OpenAI](#)
- [Android Auto is now one \(screen\) size fits all](#)
- [Google announces its Chromebook successor: the Googlebook](#)

爱范儿

- [vivo Y600 Pro 体验：这部「充电宝手机」，为什么对 vivo 很重要](#)
- [Android Auto 全面更新，看齐 Carplay！还有更「懂车」的 Gemini](#)
- [大疆 Pocket 4P 上手体验：欲穷千里目，更多摄像头](#)
- [火过 iPhone？美国「小天才电话」爆红，「什么都不行」是最大卖点](#)
- [时隔 22 年重返 V8 市场！莲花 1000 马力混动超跑曝光](#)
- [当 AI Agent 走向无处不在，MediaTek 想做的不只是手机芯片](#)
- [谷歌发布安卓 AI 系统，这就是苹果想象中的自己](#)
- [内存正在毁掉一切](#)
- [早报 | Android 17 转型智能系统，深度整合 AI/腾讯：微信已读和访客功能「已焊死」，不会开发/李想：理想自研芯片不是跟风](#)
- [理想 L9 Livis，凭什么对标法拉利和保时捷？](#)
- [刚刚，宇树载人机甲发布，售价 390 万起](#)
- [Seedance 2.0 最强对手偷跑了](#)
- [有史以来最大的奥迪！奥迪 Q9 内饰细节公布，摒弃钢琴烤漆，提供六/七座布局](#)
- [Markdown 已死，HTML 当立？](#)
- [小米 YU7 GT 定档 5 月 21 日，预计售价 40 万，还有更便宜的 YU7 「青春版」将一同亮相](#)
- [早报 | 曝苹果新 Vision Pro 研发已暂停，团队分拆/黄仁勋：AI 让所有人站上同一条起跑线/微信状态将推出「访客记录」](#)
- [售价破千万！兰博基尼用 V12+三电机，再次刷新敞篷车上限](#)
- [激光雷达上车！比亚迪 2026 款海鸥发布，6.99 万元起](#)
- [下个月的苹果 WWDC，假如 iCloud 变成 iClaw.....?](#)
- [中国拿下这届 AI 顶会半壁江山，清华一家单挑斯坦福加 MIT](#)

二、■ arXiv 论文精选（15 篇 | 中文摘要）

方向：大模型 / 推荐系统 / 生成式推荐 / 广告排序 / 多模态

1. HSUGA：层次语义理解与群体感知对齐的 LLM 增强推荐

原题：HSUGA: LLM-Enhanced Recommendation with Hierarchical Semantic Understanding and Group-Aware Alignment

核心贡献：双路改进 LLM 序列推荐的用户语义建模与协同对齐

现有 LLM 增强序列推荐方法在用户语义嵌入提取和利用上存在不足。HSUGA 提出层次语义理解模块（捕捉细粒度用户行为），并引入群体感知对齐机制，将具有相似兴趣的用户群体信息融入推荐建模。在多个公开基准上取得显著提升，相关度极高。

作者：Guorui Li, Dugang Liu, Lei Li, Xing Tang | arXiv cs.IR (信息检索/推荐系统) | 相关度

12

2. RecRM-Bench：面向智能体推荐系统的多维度奖励建模基准

原题: *RecRM-Bench: Benchmarking Multidimensional Reward Modeling for Agentic Recommender Systems*

核心贡献: 首个针对推荐 Agent 的多维奖励模型评测基准

LLM Agent 正在将推荐系统从简单的 query-item 匹配升级为深度个性化的交互式推荐, RLHF 中奖励模型的质量成为关键瓶颈。本文提出 RecRM-Bench, 从多个维度(相关性、多样性、新颖性、公平性等)系统评测推荐场景下的奖励模型, 填补当前评测体系空白。

作者: Wenwen Zeng, Jinhui Zhang, Hao Chen, Zhaoyu Hu | arXiv cs.IR (信息检索/推荐系统) | 相关度 9

3. 重思欺诈与反洗钱场景下的 LLMOps: 构建合规级 LLM 服务栈

原题: *Rethinking LLMOps for Fraud and AML: Building a Compliance-Grade LLM Serving Stack*

核心贡献: 金融合规场景 LLM 推理栈的工程化落地方案

欺诈检测和反洗钱是 LLM 落地的高价值垂直场景, 但其推理要求与通用 Chat 服务差异显著: 监管合规约束、低延迟、可解释性和审计追溯缺一不可。本文系统分析金融合规场景的 LLM 服务需求, 提出专属的 LLMOps 架构, 对大厂内部合规 AI 落地有直接参考价值。

作者: Prathamesh Vasudeo Naik, Naresh Dintakurthi, Yue Wang | arXiv cs.LG (机器学习) | 相关度 9

4. HiDream-O1-Image: 像素级统一 Transformer 的原生图像生成基础模型

原题: *HiDream-O1-Image: A Natively Unified Image Generative Foundation Model with Pixel-level Unified Transformer*

核心贡献: 打破分离式架构, 统一文本编码器与 VAE 的图像生成基础模型

视觉生成模型长期依赖分离的文本编码器和外部 VAE, 导致架构碎片化。HiDream-O1-Image 提出像素级统一 Transformer 架构, 将图像理解与生成原生统一, 无需外部组件。在多个图像生成基准上达到 SOTA, 代表多模态生成模型的一个重要架构演进方向。

作者: Qi Cai, Jingwen Chen, Chengmin Gao, Zijian Gong | arXiv cs.CV (计算机视觉/多模态) | 相关度 9

5. TwiSTAR: 快慢思考自适应的生成式推荐

原题: *TwiSTAR: Think Fast, Think Slow, Then Act, Generative Recommendation with Adaptive Dual-Speed Reasoning*

核心贡献: 自适应快慢推理策略提升生成式推荐的效率与效果

基于语义 ID 的生成式推荐已成为主流范式, 但现有方法固定推理策略(快速直接生成或慢速 CoT 推理), 无法按场景动态切换。TwiSTAR 引入自适应双速推理机制, 低复杂度请求走快路, 高不确定性请求走慢路 CoT, 在效率和效果上均优于单一策略基线。

6. 行为曲线中的辛普森悖论: 聚合如何扭曲推荐与广告的参数化模型

原题: *Simpson's Paradox in Behavioral Curves: How Aggregation Distorts Parametric Models in Recommendation and Advertising*

核心贡献： 揭示推荐/广告建模中聚合操作导致辛普森悖论的内在机制

在推荐、广告和临床剂量建模中，将参数函数拟合到「参与度-曝光量」数据是标准做法。本文证明聚合操作会系统性地引入辛普森悖论，导致估计出的曲线在宏观层面与微观层面规律相反，对依赖聚合数据训练的推荐/广告模型提出根本性警示。

7. PIVOT：通过轨迹精化弥合 LLM Agent 的规划与执行鸿沟

原题：PIVOT: Bridging Planning and Execution in LLM Agents via Trajectory Refinement

核心贡献： 轨迹精化框架解决 LLM Agent 「计划可行、执行失败」的核心矛盾

LLM Agent 经常生成表面合理但执行失败的计划，原因是动作不可行、约束违反和长时域误差累积。PIVOT 提出轨迹精化机制，在执行过程中动态检测和修正规划偏差，在多个 Agent 基准上显著提升任务完成率，对构建可靠的 AI Agent 系统有实践价值。

8. 面向长文档的高效列表式多模态重排序

原题：Very Efficient Listwise Multimodal Reranking for Long Documents

核心贡献： 大幅提升多模态 RAG 中长文档重排序的计算效率

列表式重排序是多模态检索增强生成（M-RAG）的关键但计算昂贵的环节。本文提出高效列表式多模态重排序方法，在保持精度的同时显著降低计算代价，对构建实际可部署的多模态 RAG 系统（推荐/搜索场景）有直接参考价值。

9. EHR-RAGp：面向电子健康记录的检索增强原型引导基础模型

原题：EHR-RAGp: Retrieval-Augmented Prototype-Guided Foundation Model for Electronic Health Records

核心贡献： RAG 结合原型引导提升 EHR 纵向数据的预测建模能力

电子健康记录包含丰富的纵向患者信息，但有效利用历史数据仍具挑战。EHR-RAGp 将检索增强生成与原型引导机制结合，显著提升了基础模型在 EHR 预测任务上的表现，RAG 在结构化数据场景的应用方法论有一定参考价值。

10. 退化感知提示驱动的多模态 LLM 一体化图像修复

原题：Leveraging Multimodal Large Language Models for All-in-One Image Restoration via Degradation-Aware Prompting

核心贡献： 退化感知提示让多模态 LLM 统一处理多种图像损坏类型

全合一图像修复旨在用统一框架恢复受多种未知退化影响的图像。本文将多模态 LLM 与退化感知提示结合，无需为每种退化类型单独训练模型，在去噪、去雨、去雾等任务上均达到有竞争力的性能，多模态 LLM 在底层视觉任务的通用化能力进一步验证。

11. Instruct-ICL：指令引导上下文学习的灾后损毁评估

原题：Instruct-ICL: Instruction-Guided In-Context Learning for Post-Disaster Damage Assessment

核心贡献： 指令引导 ICL 提升灾后场景理解，无需任务专属训练

灾后快速态势感知需要高效准确的图像分析，但训练任务专属模型耗时耗资源。Instruct-ICL 利用指令引导的上下文学习，在无需微调的情况下快速适配灾后损毁评估任务，展示了 ICL 在垂直场景快速迁移的可行性。

12. 社交媒体因果关系抽取中的大语言模型：验证研究

原题: *Large Language Models for Causal Relations Extraction in Social Media: A Validation Study*

核心贡献: 验证 LLM 在社交媒体灾情因果关系抽取中的可靠性

灾情中从社交媒体抽取因果关系可增强态势感知。本文系统验证多种 LLM 在该任务上的表现，评估其识别伤亡、基础设施损毁等因素之间因果链条的能力，为信息抽取任务的 LLM 选型提供实证依据。

13. 模板即本体：可配置合成数据基础设施用于跨领域 LLM Agent 验证

原题: *Template-as-Ontology: Configurable Synthetic Data Infrastructure for Cross-Domain LLM Agent Validation*

核心贡献: 可配置合成数据框架解决生产环境 LLM Agent 验证的数据困境

制造环境中 LLM Agent 需要结构正确的数据进行验证，但生产 MES 数据存在隐私和专有权问题。本文提出「模板即本体」框架，支持跨领域可配置合成数据生成，为企业 LLM Agent 落地验证提供数据基础设施方案。

14. ClinicalBench: 跨就诊临床 NLP 的断言感知检索压力测试基准

原题: *ClinicalBench: Stress-Testing Assertion-Aware Retrieval for Cross-Admission Clinical NLP*

核心贡献: 评测真实 EHR 检索中否定、时态、家族病史等复杂语言现象的处理能力

推理基准测试干净输入，本文聚焦推理前的关键一步：在真实 EHR 文本上的检索，其中包含否定、时态表达、家族 vs. 患者属性等复杂语言现象。ClinicalBench 系统评测主流检索方法的鲁棒性，对构建可靠的临床 AI 系统有直接意义。

15. 从查询到对话：智能体搜索与信息检索的演进

原题: *From Queries to Conversations: Agentic Search and the Evolution of Information Retrieval*

核心贡献: 系统综述 LLM Agent 驱动搜索范式转变

信息检索正在从单次查询模式向多轮对话式智能体搜索演进。本文系统梳理这一转变的技术路径、关键挑战和未来方向，覆盖意图理解、工具调用、多步推理和检索增强生成等核心模块，对搜索/推荐系统架构演进有宏观参考价值。

生成时间: 2026-05-13 17:42 (北京时间)